

FIAP - ACLIMAÇÃO
Ciências da Computação

ARTHUR MAZIVIERO FARIA. RM: 573928
JUN UEHARA. RM: 570537
FELIPE DE SOUZA GALLO. RM: 569680
ROBERSON REGUERO LUIZ JUNIOR. RM: 573031
TOMMASO CONCEIÇÃO NAGLIATTI. RM: 572147
MATHEUS MARTINS LACERDA. RM: 570843

SPRINT 3
MODELAGEM LINEAR PARA APRENDIZADO
DE MÁQUINA

Estatística com Python

SÃO PAULO
2026

ARTHUR MAZIVIERO FARIA. RM: 573928
JUN UEHARA. RM: 570537
FELIPE DE SOUZA GALLO. RM: 569680
ROBERSON REGUERO LUIZ JUNIOR. RM: 573031
TOMMASO CONCEIÇÃO NAGLIATTI. RM: 572147
MATHEUS MARTINS LACERDA. RM: 570843

SPRINT 3
MODELAGEM LINEAR PARA APRENDIZADO
DE MÁQUINA

Estatística com Python

Relatório da Sprint 3 apresentado ao curso de Ciências da Computação da Instituição de Ensino Superior FIAP - ACLIMAÇÃO, na disciplina Estatística com Python.

1. Objetivo e visão geral

Este trabalho analisa a variável aleatória gasto familiar sob a hipótese de que ela segue uma Distribuição Normal. Em seguida, ajusta uma Regressão Linear Simples para explicar o gasto familiar a partir da renda familiar. Todo o procedimento foi desenvolvido em Python e estruturado para execução no Google Colab.

Resultados principais

Indicador	Resultado
Probabilidade acima da mediana	44.36% - provável
Probabilidade em média $\pm 2s$	95.45% - quase certo
Equação estimada	$\text{gasto} = 207.9033 + 0.2973 \times \text{renda}$
Coefficiente de determinação	$R^2 = 0.9699$

Base de dados

A base contém 50 famílias e duas variáveis monetárias: renda familiar e gasto familiar. Os valores reproduzem o conjunto didático apresentado no conteúdo de correlação e regressão da Alura indicado no enunciado. Um identificador foi acrescentado para diferenciar os registros, e a coluna `autores_trabalho` registra todos os nomes completos e RMs. Essas colunas não entram na análise. Trata-se da alternativa de nova base ajustada permitida no enunciado, sob a hipótese de normalidade exigida para os cálculos.

Variável	Descrição
<code>renda_familiar</code>	Renda total observada para cada família, em reais.
<code>gasto_familiar</code>	Gasto total observado para cada família, em reais.
<code>id_familia</code>	Identificador sequencial sem papel no modelo.
<code>autores_trabalho</code>	Identificação do grupo; excluída dos cálculos.

Critério de classificação dos eventos

Foram adotadas faixas explícitas: raro para probabilidade de até 5%; pouco provável acima de 5% e até 25%; provável acima de 25% e até 75%; e quase certo acima de 75%. O enunciado não define os limites numéricos dessas categorias; as faixas são uma convenção explícita adotada neste trabalho.

2. Probabilidade acima da mediana

A mediana divide os dados observados em duas metades. Como o exercício solicita uma probabilidade baseada em uma Distribuição Normal parametrizada com a média e o desvio padrão amostrais, calculamos a área à direita da mediana amostral usando a função de sobrevivência da Normal.

Código utilizado

```
gastos = dados['gasto_familiar']
media = gastos.mean()
mediana = gastos.median()
desvio = gastos.std(ddof=1)
prob_acima_mediana = norm.sf(
    mediana, loc=media, scale=desvio
)
```

Cálculo	Resultado
Mediana amostral	R\$ 2.127,00
Média usada na Normal	R\$ 2.011,12
Desvio padrão amostral	R\$ 817,21
$P(X > \text{mediana})$	44.3619%
Classificação	Provável

Interpretação

A probabilidade de um gasto selecionado ao acaso ultrapassar a mediana de R\$ 2.127,00 é de aproximadamente 44,36%. O evento é classificado como provável. O valor não precisa ser exatamente 50%: a mediana usada é a da amostra, enquanto a curva Normal é definida pela média e pelo desvio padrão estimados. Como média e mediana amostrais diferem, a área calculada também se afasta de 50%.




Figura 1 - Distribuição Normal ajustada ao gasto familiar.

3. Probabilidade no intervalo média $\pm 2s$

O segundo evento corresponde à faixa compreendida entre dois desvios padrão abaixo e dois desvios padrão acima da média. Para uma Normal, a probabilidade é obtida subtraindo a função de distribuição acumulada no limite inferior da função acumulada no limite superior.

Código utilizado

```
limite_inferior = media - 2 * desvio
limite_superior = media + 2 * desvio
prob_intervalo = (
    norm.cdf(limite_superior, loc=media, scale=desvio)
    - norm.cdf(limite_inferior, loc=media, scale=desvio)
)
```

Cálculo	Resultado
Média	R\$ 2.011,12
Desvio padrão amostral (s)	R\$ 817,21
Limite inferior (média - 2s)	R\$ 376,69
Limite superior (média + 2s)	R\$ 3.645,55
Probabilidade no intervalo	95.4500%
Classificação	Quase certo

Interpretação

O intervalo vai de R\$ 376,69 a R\$ 3.645,55 e concentra aproximadamente 95,45% da probabilidade do modelo Normal. O evento é classificado como quase certo. Esse resultado coincide com a regra empírica da Normal segundo a qual cerca de 95% dos valores ficam a até dois desvios padrão da média.

A faixa sombreada em azul na Figura 1 representa esse intervalo. A área laranja evidencia, ao mesmo tempo, o evento acima da mediana usado no primeiro exercício.

4. Modelagem com Regressão Linear

Foi ajustada uma Regressão Linear Simples pelo método dos mínimos quadrados. A variável dependente é o gasto familiar e a variável explicativa é a renda familiar. O modelo assume a forma $\text{gasto} = \text{intercepto} + \text{coeficiente} \times \text{renda} + \text{erro}$.

Código utilizado

```
X = dados[['renda_familiar']]
y = dados['gasto_familiar']
modelo = LinearRegression()
modelo.fit(X, y)
previsoes = modelo.predict(X)
r2 = r2_score(y, previsoes)
rmse = np.sqrt(mean_squared_error(y, previsoes))
```

Parâmetro ou métrica	Estimativa
Intercepto	207.9033
Coeficiente da renda	0.2973
R ²	0.9699
RMSE	R\$ 140,36

A reta estimada é: $\text{gasto} = 207.9033 + 0.2973 \times \text{renda}$.




Figura 2 - Observações e reta de Regressão Linear ajustada.

5. Interpretação da regressão

Intercepto

O intercepto estimado é 207.9033. Ele representa um gasto previsto de aproximadamente R\$ 207,90 quando a renda é zero. Como a amostra começa em renda superior a R\$ 1.000,00, essa interpretação é apenas matemática e corresponde a uma extrapolação para fora da faixa observada.

Coeficiente angular

O coeficiente da renda é 0.2973. Portanto, cada aumento de R\$ 1,00 na renda está associado, em média, a um aumento esperado de cerca de R\$ 0.2973 no gasto. Em uma escala mais intuitiva, R\$ 1.000,00 adicionais de renda correspondem a aproximadamente R\$ 297,29 adicionais de gasto previsto.

Qualidade do ajuste

O R^2 de 0.9699 indica que cerca de 96.99% da variação observada no gasto é explicada linearmente pela renda nesta amostra. O RMSE de R\$ 140,36 representa a magnitude típica dos erros de previsão dentro dos dados utilizados no ajuste.

Limites da interpretação

O modelo identifica uma associação linear forte, mas não demonstra que a renda seja a única causa do gasto. Tamanho da família, localização, dívidas e hábitos de consumo podem influenciar o resultado. Além disso, previsões muito além da faixa de renda observada devem ser evitadas.

Relação entre estatística e aprendizado de máquina

A Distribuição Normal fornece uma linguagem probabilística para representar incerteza e classificar eventos. A Regressão Linear usa dados observados para estimar parâmetros e produzir previsões. Assim, a estatística sustenta o aprendizado de máquina ao oferecer medidas de tendência, variabilidade, erro e qualidade do ajuste. O modelo aprende uma regra numérica a partir dos exemplos, enquanto as métricas ajudam a avaliar o quanto essa regra representa os dados.

6. Execução no Google Colab

O notebook challenge_sprint_3.ipynb foi organizado em células sequenciais. Para executar a análise no Colab, abra o notebook e selecione Executar tudo. Quando solicitado, envie o CSV entregue com o trabalho. O código e os testes estão incorporados no notebook e não dependem do GitHub. A última célula executa a suíte completa de testes do projeto e as verificações dos resultados do notebook. O ambiente do Colab já inclui as bibliotecas principais utilizadas pelo trabalho.

Bibliotecas

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from scipy.stats import norm
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
```

Arquivos da entrega

Arquivo	Finalidade
dados_familias.csv	Base de dados obrigatória em formato CSV.
analise_estadistica.py	Código Python obrigatório com a análise completa.
Relatorio_Sprint_3.pdf	Relatório com códigos, gráficos e interpretações.

7. Conclusão

A análise respondeu aos três itens quantitativos do desafio. A chance de o gasto superar a mediana foi classificada como provável; a chance de permanecer a até dois desvios padrão da média foi classificada como quase certa; e a renda explicou aproximadamente 96,99% da variação dos gastos no modelo linear. Os resultados mostram uma aplicação integrada de probabilidade, estatística descritiva e aprendizado supervisionado.

8. Validação automatizada

O notebook foi executado integralmente. Sua última célula executou os 10 testes do projeto e 6 testes dos resultados do notebook, totalizando 16 testes aprovados, sem falhas. As verificações abrangem a base de 50 famílias, as estatísticas, as probabilidades, os limites de classificação, a regressão e a consistência com o módulo Python.

9. Requisitos de entrega

Um único representante deve enviar diretamente no Portal os três arquivos obrigatórios: o relatório PDF, dados_familias.csv e analise_estatistica.py. Todos contêm os nomes completos e RMs dos seis integrantes. O notebook, modelo.md e integrantes.txt são complementares e não substituem os formatos obrigatórios. Não entregar apenas links nem usar o ZIP como substituto dos arquivos solicitados.

Todos os integrantes são responsáveis pela entrega final. O envio deve ser concluído antes do prazo registrado no Portal. Após o encerramento, não há novo envio nem substituição. A orientação prevê desconto de 1,0 ponto por item ausente ou não atendido. A data do prazo não consta no trecho recebido.

Correspondência com a avaliação

Item 01 (2,5 pontos): mediana, probabilidade, código e classificação, na seção 2. Item 02 (2,5 pontos): média, desvio padrão, intervalo, probabilidade, código e classificação, na seção 3. Item 03 (3,0 pontos): regressão, gráfico e coeficientes, nas seções 4 e 5. Item 04 (2,0 pontos): códigos, gráficos e explicações neste PDF, com relação entre estatística e aprendizado de máquina na seção 5 e na conclusão.

Execução do arquivo Python obrigatório

```
# No Colab, envie o .py e o CSV para a aba Arquivos.  
%run analise_estatistica.py --arquivo dados_familias.csv
```

O script gera os dois gráficos na pasta resultados e exibe as estatísticas, probabilidades, classificações e métricas. Localmente, execute `python analise_estatistica.py --arquivo dados_familias.csv` após instalar as bibliotecas usadas. O notebook é uma opção complementar, com a suíte de testes na última célula.

Referências

ALURA. Estatística com Python: Correlação e Regressão. Base didática de 50 famílias e referência para regressão. Disponível em: <https://www.alura.com.br/conteudo/estatistica-correlacao-regressao>. Acesso em: 20 set. 2026.

ALURA. Cálculo da probabilidade da distribuição normal com quaisquer valores de média e desvio padrão. Fórum, resposta de João Vitor de Miranda, 14 jan. 2022. Referência para os parâmetros loc (média) e scale (desvio padrão) de `scipy.stats.norm`. Acesso em: 20 set. 2026.