

SPRINT 3

Modelagem Linear para Aprendizado de Máquina

Estatística com Python

Integrantes

Arthur Maziviero Faria - RM 573928

Jun Uehara - RM 570537

Felipe de Souza Gallo - RM 569680

Roberson Reguero Luiz Junior - RM 573031

Tommaso C. Nagliatti - RM 572147

Matheus Martins Lacerda - RM 570843

Link: <https://github.com/felipe-gallo/challenge-sprint-3-estatistica-python>

1. Objetivo e visão geral

Este trabalho analisa a variável aleatória gasto familiar sob a hipótese de que ela segue uma Distribuição Normal. Em seguida, ajusta uma Regressão Linear Simples para explicar o gasto familiar a partir da renda familiar. Todo o procedimento foi desenvolvido em Python e estruturado para execução no Google Colab.

Resultados principais

Indicador	Resultado
Probabilidade acima da mediana	44.36% - provável
Probabilidade em média $\pm 2s$	95.45% - quase certo
Equação estimada	$\text{gasto} = 207.9033 + 0.2973 \times \text{renda}$
Coefficiente de determinação	$R^2 = 0.9699$

Base de dados

A base contém 50 famílias e duas variáveis monetárias: renda familiar e gasto familiar. Os valores reproduzem o conjunto didático apresentado no conteúdo de correlação e regressão da Alura indicado no enunciado. Um identificador foi acrescentado apenas para diferenciar os registros.

Variável	Descrição
renda_familiar	Renda total observada para cada família, em reais.
gasto_familiar	Gasto total observado para cada família, em reais.
id_familia	Identificador sequencial sem papel no modelo.

Critério de classificação dos eventos

Foram adotadas faixas explícitas: raro para probabilidade de até 5%; pouco provável acima de 5% e até 25%; provável acima de 25% e até 75%; e quase certo acima de 75%.

2. Probabilidade acima da mediana

A mediana divide os dados observados em duas metades. Como o exercício solicita uma probabilidade baseada em uma Distribuição Normal parametrizada com a média e o desvio padrão amostrais, calculamos a área à direita da mediana amostral usando a função de sobrevivência da Normal.

Código utilizado

```
gastos = dados['gasto_familiar']
media = gastos.mean()
mediana = gastos.median()
desvio = gastos.std(ddof=1)
prob_acima_mediana = norm.sf(
    mediana, loc=media, scale=desvio
)
```

Cálculo	Resultado
Mediana amostral	R\$ 2.127,00
Média usada na Normal	R\$ 2.011,12
Desvio padrão amostral	R\$ 817,21
$P(X > \text{mediana})$	44.3619%
Classificação	Provável

Interpretação

A probabilidade de um gasto selecionado ao acaso ultrapassar a mediana de R\$ 2.127,00 é de aproximadamente 44,36%. O evento é classificado como provável. O valor não precisa ser exatamente 50%: a mediana usada é a da amostra, enquanto a curva Normal é definida pela média e pelo desvio padrão estimados. Como média e mediana amostrais diferem, a área calculada também se afasta de 50%.




Figura 1 - Distribuição Normal ajustada ao gasto familiar.

3. Probabilidade no intervalo média $\pm 2s$

O segundo evento corresponde à faixa compreendida entre dois desvios padrão abaixo e dois desvios padrão acima da média. Para uma Normal, a probabilidade é obtida subtraindo a função de distribuição acumulada no limite inferior da função acumulada no limite superior.

Código utilizado

```
limite_inferior = media - 2 * desvio
limite_superior = media + 2 * desvio
prob_intervalo = (
    norm.cdf(limite_superior, loc=media, scale=desvio)
    - norm.cdf(limite_inferior, loc=media, scale=desvio)
)
```

Cálculo	Resultado
Média	R\$ 2.011,12
Desvio padrão amostral (s)	R\$ 817,21
Limite inferior (média - 2s)	R\$ 376,69
Limite superior (média + 2s)	R\$ 3.645,55
Probabilidade no intervalo	95.4500%
Classificação	Quase certo

Interpretação

O intervalo vai de R\$ 376,69 a R\$ 3.645,55 e concentra aproximadamente 95,45% da probabilidade do modelo Normal. O evento é classificado como quase certo. Esse resultado coincide com a regra empírica da Normal segundo a qual cerca de 95% dos valores ficam a até dois desvios padrão da média.

A faixa sombreada em azul na Figura 1 representa esse intervalo. A área laranja evidencia, ao mesmo tempo, o evento acima da mediana usado no primeiro exercício.

4. Modelagem com Regressão Linear

Foi ajustada uma Regressão Linear Simples pelo método dos mínimos quadrados. A variável dependente é o gasto familiar e a variável explicativa é a renda familiar. O modelo assume a forma $\text{gasto} = \text{intercepto} + \text{coeficiente} \times \text{renda} + \text{erro}$.

Código utilizado

```
X = dados[['renda_familiar']]
y = dados['gasto_familiar']
modelo = LinearRegression()
modelo.fit(X, y)
previsoes = modelo.predict(X)
r2 = r2_score(y, previsoes)
rmse = np.sqrt(mean_squared_error(y, previsoes))
```

Parâmetro ou métrica	Estimativa
Intercepto	207.9033
Coeficiente da renda	0.2973
R ²	0.9699
RMSE	R\$ 140,36

A reta estimada é: $\text{gasto} = 207.9033 + 0.2973 \times \text{renda}$.




Figura 2 - Observações e reta de Regressão Linear ajustada.

5. Interpretação da regressão

Intercepto

O intercepto estimado é 207.9033. Ele representa um gasto previsto de aproximadamente R\$ 207,90 quando a renda é zero. Como a amostra começa em renda superior a R\$ 1.000,00, essa interpretação é apenas matemática e corresponde a uma extrapolação para fora da faixa observada.

Coeficiente angular

O coeficiente da renda é 0.2973. Portanto, cada aumento de R\$ 1,00 na renda está associado, em média, a um aumento esperado de cerca de R\$ 0.2973 no gasto. Em uma escala mais intuitiva, R\$ 1.000,00 adicionais de renda correspondem a aproximadamente R\$ 297,29 adicionais de gasto previsto.

Qualidade do ajuste

O R^2 de 0.9699 indica que cerca de 96.99% da variação observada no gasto é explicada linearmente pela renda nesta amostra. O RMSE de R\$ 140,36 representa a magnitude típica dos erros de previsão dentro dos dados utilizados no ajuste.

Limites da interpretação

O modelo identifica uma associação linear forte, mas não demonstra que a renda seja a única causa do gasto. Tamanho da família, localização, dívidas e hábitos de consumo podem influenciar o resultado. Além disso, previsões muito além da faixa de renda observada devem ser evitadas.

Relação entre estatística e aprendizado de máquina

A Distribuição Normal fornece uma linguagem probabilística para representar incerteza e classificar eventos. A Regressão Linear usa dados observados para estimar parâmetros e produzir previsões. Assim, a estatística sustenta o aprendizado de máquina ao oferecer medidas de tendência, variabilidade, erro e qualidade do ajuste. O modelo aprende uma regra numérica a partir dos exemplos, enquanto as métricas ajudam a avaliar o quanto essa regra representa os dados.

6. Execução no Google Colab

O notebook challenge_sprint_3.ipynb foi organizado em células sequenciais. Para executar a análise no Colab, faça upload do notebook, execute todas as células e, quando solicitado, selecione o arquivo dados_familias.csv. O ambiente do Colab já inclui as bibliotecas principais utilizadas pelo trabalho.

Bibliotecas

```
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
from scipy.stats import norm
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score
```

Arquivos da entrega

Arquivo	Finalidade
dados_familias.csv	Base de dados obrigatória em formato CSV.
analise_estadistica.py	Código Python obrigatório com a análise completa.
challenge_sprint_3.ipynb	Notebook adicional pronto para o Google Colab.
Sprint_3_Modelagem_Linear.pdf	Relatório com códigos, gráficos e interpretações.

7. Conclusão

A análise respondeu aos três itens quantitativos do desafio. A chance de o gasto superar a mediana foi classificada como provável; a chance de permanecer a até dois desvios padrão da média foi classificada como quase certa; e a renda explicou aproximadamente 96,99% da variação dos gastos no modelo linear. Os resultados mostram uma aplicação integrada de probabilidade, estatística descritiva e aprendizado supervisionado.